

Análise de Desempenho de RAG Multilíngue

Relatório Final de Pesquisa

Luccas da Silva Lima

Universidade Federal do Rio Grande do Sul

luccas.lima@ufrgs.br

2026

O Desafio:

- Entender como a escolha do idioma pode impactar a qualidade de um sistema RAG.

Objetivo do Estudo: Descobrir qual ou quais linguagens são mais eficientes para a construção de um sistema RAG.

2.1 Reprodutibilidade

Fluxo de Desenvolvimento e Gestão:

- **Linguagem Base:** Python.
- **Controle de Versão:** GitHub, com READMEs detalhando o escopo e a ordem de execução dos scripts.
- **Gestão de Dependências:** Isolamento de ambiente e consistência de bibliotecas garantidos via Poetry.
- **Garantia:** Total rastreabilidade e replicação fiel do ambiente de experimentos.

2.2 Ambiente de Execução

Infraestrutura Local:

- **CPU:** Intel Core i5-12400F
- **GPU:** NVIDIA GeForce RTX 4060 (8 GB VRAM)
- **RAM & Disco:** 32 GB | SSD Kingston NVMe 1 TB

Processamento Externo (Tradução):

- Requisições via API da OpenAI (LLM gpt-5.1) devido às elevadas exigências computacionais da etapa de tradução.

2.3 Criação dos Documentos Originais e Tradução

Geração do Corpus Base:

- Criação de 10 documentos de referência formatados em Markdown, originalmente em Inglês (en_us).

Processo de Tradução:

- Expansão linguística conduzida por um LLM operando em modo *zero-shot*.
- Aplicação de restrições no prompt para garantir a preservação estrita da formatação.
- Prevenção contra sumarizações automáticas ou perda de numeração de linhas, garantindo paridade semântica.

2.3.1 Idiomas Avaliados


Escopo Multilíngue (20 Idiomas):

- ar_sa: Árabe (Arábia Saudita)
- cs_cz: Tcheco (República Tcheca)
- da_dk: Dinamarquês (Dinamarca)
- de_de: Alemão (Alemanha)
- en_gb: Inglês (Reino Unido)
- en_us: Inglês (Estados Unidos)
- es_es: Espanhol (Espanha)
- fr_fr: Francês (França)
- hi_in: Hindi (Índia)
- it_it: Italiano (Itália)
- ja_jp: Japonês (Japão)
- ko_kr: Coreano (Coreia do Sul)
- nl_nl: Holandês (Países Baixos)
- pl_pl: Polonês (Polônia)
- pt_br: Português (Brasil)
- ru_ru: Russo (Rússia)
- sv_se: Sueco (Suécia)
- tr_tr: Turco (Turquia)
- zh_cn: Chinês (Simplificado)
- zh_tw: Chinês (Tradicional)

2.3.2 O Impacto da Verbosidade

A Variabilidade Inerente:

- Mesmo mantendo o exato mesmo significado e formatação, a estrutura de cada língua muda drasticamente o tamanho do arquivo final.
- Idiomas mais expansivos resultaram em contagens de caracteres muito superiores ao original em inglês.



2.4 Design de Experimentos (DoE)

Abordagem Fatorial Completo (*Full Factorial*):


Variável Controlada	Níveis
Tamanho do Lote (<i>Batch Size</i>)	7 configurações
Tamanho do Fragmento (<i>Chunk Size</i>)	7 configurações
Precisão Numérica (<i>Precision</i>)	float32 e float16
Métrica de Distância (FAISS)	L2 e <i>Inner Product</i>

- **Cobertura:** 20 idiomas avaliados em 10 replicações.
- **Volume de Dados:** 39.200 configurações totais durante a geração das bases de dados.
- **Processamento Exclusivo (CUDA):** A variável *device* (CPU vs. GPU) foi removida do escopo. A execução combinatória do Fatorial Completo em CPU tornaria o tempo de experimento impraticável.

2.5 Tamanho do Banco de Dados por Idioma

O Custo da Verbosidade:


- Variação na quantidade de caracteres impacta diretamente o armazenamento.
- O custo em disco do índice vetorial cresce proporcionalmente à verbosidade da língua analisada.



2.6 Tempo de Embedding por Idioma


Tempo Absoluto por Idioma

Tempo total de embedding por idioma (todos os experimentos)



Correlação: Tempo vs. Caracteres


Embedding Time × File Characters (modelo de regressão)



2.7 Tamanho do Fragmento vs. Armazenamento Total

Equilíbrio Contextual:

- Fragmentos (*chunks*) menores geram mais vetores densos.
- Independentemente do idioma, o aumento de metadados de fragmentos menores aumenta também o armazenamento total.



2.8 Estrutura das Consultas (*Queries*)

Elaboração e Mapeamento *Gold Standard*:

- Foram criadas 20 perguntas, traduzidas seguindo a mesma metodologia do corpus de base.
- Cada documento da base contém a resposta direta para exatamente 2 dessas perguntas.
- Isso estabelece um *Gold Standard* determinístico: para cada pergunta, existe **uma única resposta certa** a ser encontrada no índice.

Expansão Volumétrica dos Dados:

- A matriz do DoE resultou em 39.200 bancos de dados gerados.
- Ao cruzar esse cenário com as 20 consultas, o arquivo CSV resultante atingiu a marca de **784.000 instâncias de avaliação**.

2.9 Foco no *Retrieval* e Custo Computacional

Simplificação Arquitetural:

- Inicialmente, havia um agente LLM projetado para formular a resposta final baseada nos documentos recuperados. Este passo foi removido. O escopo da pesquisa foca estritamente na qualidade do **modelo de *embeddings*** e na busca semântica. Adicionar a geração final não traria novos dados métricos, apenas aumentaria o tempo de execução dos experimentos.

Avaliação Exclusiva e Tempo de Execução:


- O pipeline avaliou exclusivamente a etapa de ***Retrieval*** (capacidade de encontrar o documento correto no Top-K).
- Mesmo com essa otimização arquitetural, o processamento e a avaliação dessas 784.000 consultas exigiu cerca de **70 horas** de execução.

2.10 Resultados das Consultas (Parte 1: Piores Posições)

Idiomas com as Piores Posições no Ranking

10 idiomas com pior posicionamento médio do arquivo correto.

Valores maiores indicam que o arquivo correto apareceu em posições mais baixas no ranking.




2.10 Resultados das Consultas (Parte 2: Melhores Posições)

Idiomas com as Melhores Posições no Ranking


10 idiomas com melhor posicionamento médio do arquivo correto.

Valores menores indicam que o arquivo correto apareceu mais próximo do topo do ranking.



2.10 Resultados das Consultas (Parte 3: Tempo de Retrieval)

Tempo Médio de Recuperação por Idioma




2.10 Resultados das Consultas (Parte 4: Falhas na Recuperação)

Percentual de Falhas Absolutas (Gold False)

Porcentagem de retrievals incorretos por idioma.

Considerado erro apenas se mais da metade das 10 replicações falharem.



Conclusões Principais:

- ❶ **A língua dita a eficiência:** A verbosidade afeta diretamente o armazenamento em disco e a latência de geração de *embeddings*.
- ❷ **Viés do Modelo Base:** Observa-se uma disparidade de desempenho em favor do idioma inglês e francês, reflexo da maior densidade de dados de treinamento nesses idiomas no modelo multilíngue.
- ❸ **Falhas em Línguas Complexas:** Idiomas como *sv_se* (Sueco) e *zh_tw* (Chinês Tradicional) apresentaram falhas críticas na etapa de *retrieval*.

Trabalhos Futuros:

- Investigar *fine-tuning* para o modelo de *embeddings* com o objetivo de melhorar o desempenho em idiomas de menor performance.
- Testar outros modelos de *embeddings* multilíngues para avaliar se o viés observado é específico do modelo atual ou uma tendência geral.